

목차

- 엔트로피
- 크로스 엔트로피
- KL 발산

1. 엔트로피

- "정보의 양, 불확실성을 수치로 나타낸 개념"
- **예측하기 어려울수록 엔트로피가 크다**
- **예측하기 쉬울수록 엔트로피가 작다**

"엔트로피는 여러 가지 중에서 하나를 고를 때, 얼마나 헛갈리는지를 숫자로 나타낸 것"

'엔트로피'는 정보량을 나타낸다.

- 엔트로피가 크다 = 정보량이 많다(크다)=예측하지 못한 사건이 일어났다.
- 엔트로피가 작다 = 정보량이 적다

• **Entropy** : 정보를 최적으로 인코딩하기 위해 필요한 bit의 수

$$\log_2 N = 3\text{비트}$$

ex) 오늘이 무슨 요일인지 bit로 전송한다. → 3bit 필요

$$N=8$$

월: 000, 화: 001, 수: 010, 목: 011, 금: 100, 토: 101, 일: 110

“어떻게 하면 최적으로 정보를 압축시킬 수 있을까?
예) 월-일(7일) 표현하기 위해서는 3비트 필요함..

Q1. "요일을 표현하기 위해 3비트가 필요하다. 엔트로피는 3이다." 옳은가?

구분	값	의미
엔트로피	약 2.807 bits	요일에 대한 이론적 정보량 (평균 정보량)
표현 비트 수	3 bits	컴퓨터에서 요일을 구별하기 위해 필요한 최소 정수 비트 수

요일 표현 비트수

비트 조합	요일
000	월요일
001	화요일
010	수요일
011	목요일
100	금요일
101	토요일
110	일요일
111	(미사용 또는 예비)

3비트는 총 $2^3 = 8$ 개의 조합이 가능하므로, 7개 요일 표현에 충분하며 1개는 예비로 남습니다.

확률 x 얼마나 일어나기 어려운 확률인가? 가중치들의 합

$$H(P) = - \sum_{i=1}^n p_i \log_b(p_i)$$

만약 어떤 날씨가 주어지지 않고 "무작위의 날"을 뽑는다고 생각한다면, 월요일부터 일요일까지 각 요일이 선택될 확률은 동일하게 $\frac{1}{7}$ 입니다.

- 각 요일의 확률 (p_i): $\frac{1}{7}$
- 각 요일이 얼마나 일어나기 어려운 정도 ($-\log_2(p_i)$): $-\log_2(\frac{1}{7}) = \log_2(7) \approx 2.81$ 비트

이 경우 엔트로피는 다음과 같이 계산됩니다.

$$H(\text{요일}) = - \sum_{i=1}^7 p_i \log_2(p_i) = - \sum_{i=1}^7 \frac{1}{7} \log_2(\frac{1}{7}) = -7 \times (\frac{1}{7} \times (-\log_2(7))) = \log_2(7) \approx 2.81 \text{ 비트}$$

엔트로피란? "확률분포의 불확실성"이다.

1. 모든 결과가 비슷한 확률로 나오면, 어떤 게 나올지 몰라서 더 헷갈려요. → 그래서 엔트로피가 큼니다.
2. 항상 같은 결과만 나온다면, 우리는 이미 알고 있으니 놀랄 것도 없고 → 엔트로피는 0입니다.
3. 예측이 어려운 상황일수록, 우리는 더 많은 정보를 얻고 → 그만큼 엔트로피도 커집니다.
4. 확률이 고르게 퍼질수록, '무엇이 나올까?' 하는 고민이 커지고 → 엔트로피는 높아져요.
5. 확률분포가 불균형할수록 예측은 쉬워지고 → 엔트로피는 낮아집니다.
6. 새로운 것이 없으면(놀라움도 없고, 배울것도 없고, 정보도 없으면) 엔트로피는 0이다.

확률분포가 불균형할수록 예측은 쉬워지고 → 엔트로피는 낮아진다

<예시: 편향된 주사위>

- '6'이 나올 확률: 90%
- 1-5 : 0.02

- "거의 무조건 6 나오겠네?"라고 **예측 가능**
- 놀랄 일이 거의 없음
- → **헷갈림 작음** → **엔트로피 낮음**

"확률 x 얼마나 일어나기 어려운 확률인가? 가중치 들의 합 "

엔트로피의 수학적 표현(공식)

$$H(X) = - \sum_{i=1}^n P(x_i) \log_2 P(x_i)$$

기호

의미

$H(X)$

전체 확률 변수 X 의 엔트로피 (정보량의 평균)

$P(x_i)$

i 번째 사건 x_i 이 일어날 확률

$\log_2 P(x_i)$

그 사건이 일어났을 때의 '놀라움' 정도 (정보량)

$\sum$

모든 사건에 대해 평균을 구함

$-$

로그값이 음수라 부호를 반대로 바꿈

1
2
3
4

1. 엔트로피 기본 수식

$$H(X) = - \sum_{i=1}^n p(x_i) \cdot \log_b p(x_i)$$

$$H(X) = - \sum_{i=1}^n p(x_i) \cdot \log_b p(x_i)$$

<정보량>

여기서:

- $H(X)$: 확률변수 X 의 엔트로피 (평균 정보량)
- $p(x_i)$: 각 사건 x_i 가 발생할 확률
- $\log_b$: 로그의 밑 (보통 $b = 2 \rightarrow$ 단위는 **비트**)



2. 분수 형태로 다시 쓰기

로그의 정의에 따라 다음과 같이 쓸 수 있습니다:

$$H(X) = \sum_{i=1}^n p(x_i) \cdot \log_b \left(\frac{1}{p(x_i)} \right)$$

→ **"각 사건의 확률 × 그 확률의 역수에 대한 로그" **의 합

“확률의 역수=얼마나 희귀한 사건인가?=얼마나 예측을 못했는가?”

정보량 공식:

$$I(x) = \log \left(\frac{1}{p(x)} \right)$$

- $p(x)$ = 어떤 사건이 일어날 **확률**
- $\frac{1}{p(x)}$ = 그 사건이 얼마나 **희귀한지**
- $\log$ = 사람의 인지 척도

즉, 확률이 작을수록 $\rightarrow \frac{1}{p(x)}$ 는 커짐 $\rightarrow$ 정보량 커짐

$\rightarrow$ “우와, 이게 정말 일어났다고?” 같은 느낌

#확률의 역수=정보량

$$\frac{1}{p(x)} = \text{그 사건이 얼마나 희귀한지}$$

1. 비 오는 날이 1년에 단 하루뿐이라면, 확률은 $\frac{1}{365}$, 역수는 365 → 비가 오는 건 매우 희귀하고 정보량이 큼니다.
2. 매일 학교에 가는 건 확률이 거의 1이니, 역수는 1 → 전혀 놀랍지 않고, 정보량도 거의 0입니다.
3. 로또 당첨 확률이 $1/8,000,000$ 이라면, 역수는 800만 → 당첨됐다는 건 어마어마한 정보량입니다!
4. 동전 던지기에서 앞면이 나올 확률은 $1/2$, 역수는 2 → 예상 가능성 중간, 정보량도 보통입니다.

왜 로그함수로?

$$\log_2 \left(\frac{1}{P(x)} \right)$$

1. Shannon은 3가지 조건을 만족하는 함수=정보량=로그함수

1. $P(x)$ 가 작을수록 $I(x)$ 는 커야 한다 (단조감소성)
2. 두 사건이 독립이면 $I(x, y) = I(x) + I(y)$ (덧셈성)
3. 연속적이고 부드러워야 한다 (수학적 연속성)

2. 정보량을 비트로 표현하기 위해

#주사위를 한번 던졌을 때 엔트로피(정보량)

- 주사위를 한번 던졌을 때, 어떤 숫자가 나올지 "예측이 얼마나 어려운지" 를 비트로 표현한 것

- $p(x_i) = \frac{1}{6}$ for $i = 1 \sim 6$

$$H(X) = \sum_{i=1}^6 \frac{1}{6} \cdot \log_2 \left(\frac{1}{\frac{1}{6}} \right) = 6 \cdot \frac{1}{6} \cdot \log_2(6) = \log_2(6) \approx 2.585 \text{ bits}$$

확률분포 전체의 불확실성=엔트로피

$$H(X) = - \sum p(x_i) \cdot \log p(x_i)$$

- $p(x_i)$: 각 사건이 일어날 확률
- $-\log p(x_i)$: 그 사건이 일어났을 때의 **정보량** (= 놀라움, 불확실성)
- $p(x_i) \cdot -\log p(x_i)$:
그 사건이 **실제로 일어날 확률에 비례해서**
얼마나 놀라운지를 측정한 값 → **기대 정보량**

“엔트로피란, 실제 일어난 확률과 비교하여 지금 일어난 확률이 얼마나 놀라운 확률인가?의 평균값이다.”

직관적 설명

$$H(X) = - \sum p(x_i) \cdot \log_2 p(x_i)$$

- $p(x_i)$: 얼마나 자주 일어나는가 → 사건의 확률
- $-\log_2 p(x_i)$: 그 사건이 얼마나 놀라운가 → 정보량
- 곱하기 $p(x_i) \cdot -\log_2 p(x_i)$:
 - 그 사건이 실제로 일어날 가능성을 반영해서
 - 기여하는 평균 정보량을 계산하는 것

"곱하기는 일종의 가중치"

#예시: 국어 성적 평균 구하기

과목	점수	비중(가중치)	반영점수
국어	90점	0.8	72점
체육	100점	0.2	20점

👉 단순 평균이 아니라 **비중을 곱한 가중 평균**처럼

확률 × 정보량 = 엔트로피 계산도 **가중 평균**

“손실함수”

Cross Entropy

“모델이 정답을 얼마나 정확하고 확신 있게 예측했는지를 측정하는 지표”

“정답 확률분포 기준으로 얼마나 예측하기 어려운 확률분포인가?의 가중치들의 합”

“정답 확률분포를 기준으로, 예측 확률분포가 정답에서 얼마나 멀어졌는지를 수치화한 손실 함수이다.”

Cross Entropy

두 개의 확률분포 P (정답 분포), Q (모델 예측 분포)가 있을 때:

$$\text{Cross Entropy} = H(P, Q) = - \sum_i P(x_i) \log Q(x_i)$$

기호	의미
$P(x_i)$	실제 정답(label)의 확률분포 (예: 원-핫 벡터)
$Q(x_i)$	모델이 예측한 확률분포 (softmax 결과 등)
$-\log Q(x_i)$	모델이 그 정답을 얼마나 '확신하지 못했는지'
$\sum P(x_i) \log Q(x_i)$	각 정답에 대해 가중된 로그값의 합
전체 식	**예측 분포 Q **가 **실제 분포 P **와 얼마나 다른지를 측정

크로스엔트로피 & AI

1. 예측한 확률이 정답과 얼마나 멀었는가를 정보량(놀라움)으로 측정함
2. 예측이 정답과 가까울수록 → 크로스 엔트로피 값 작아짐(불확실성이 작아짐)
3. 예측이 정답과 멀어질수록 → 값 커짐(불확실성이 커짐)
4. 분류 문제에서 **Loss function**으로 사용
5. 크로스 엔트로피를 최소화한다는 것 = 정답과 예측이 최대한 비슷하게 만들자!

#예측분포, 실제분포 & 크로스 엔트로피

1. 모델이 예측한 확률 $Q(x)$ 가 정답 클래스에 가까울수록, 실제 정답 분포 $P(x)$ 와 잘 맞아 → 크로스 엔트로피는 작습니다.
2. 정답은 하나인데, 모델이 다른 값에 높은 확률을 줬다면 → 예측 분포와 실제 분포가 멀어져서 → 크로스 엔트로피가 커집니다.
3. 정답 분포 $P(x)$ 는 보통 '1 또는 0'로 표현되기 때문에, 실제로는 모델이 정답에 부여한 확률만을 기준으로 정보량을 측정하게 됩니다.
4. 모델이 정답 클래스에 90% 확신을 가졌다면 → 정보량은 작고, 예측이 좋았다는 뜻 → 크로스 엔트로피도 낮습니다.
5. 크로스 엔트로피는 “모델이 실제로 맞춰야 할 정답을 얼마나 잘 예측했는가”를 정보량의 관점에서 평가하는 평균 손실입니다.

크로스 엔트로피, 왜 손실함수로 쓰일까?

1. 크로스 엔트로피는 예측이 정답에서 얼마나 멀었는지를 수치로 보여줌
2. 따라서 이를 최소화하는 방향으로 **모델 파라미터를 학습**시키면, 모델은 점점 더 정답에 가까운 예측을 하게 된다.
3. 크로스 엔트로피를 최소화하는 것이 '학습의 목표' 이다.

크로스 엔트로피 vs. 일반 엔트로피

구분	공식	설명
엔트로피 (자체)	$H(P) = - \sum P(x) \log P(x)$	정답 분포의 내부 불확실성
크로스 엔트로피	$H(P, Q) = - \sum P(x) \log Q(x)$	예측 Q가 정답 P와 얼마나 다른지 측정

<예시 문제> 3개 클래스 분류 문제 (예: 고양이, 강아지, 토끼)

- 실제 정답: 강아지
→ 정답 분포 $P = [0, 1, 0]$
- 모델 예측 $Q = [0.1, 0.7, 0.2]$
→ 강아지일 확률을 **0.7**로 예측함

✓ 계산 공식 적용

$$H(P, Q) = - \sum_i P(x_i) \log Q(x_i)$$

실제로는 정답 클래스만 1이고 나머지는 0이므로:

$$H(P, Q) = - (1 \cdot \log Q(\text{강아지})) = -\log 0.7$$

✓ 결과 계산

$$H(P, Q) = -\log_2 0.7 \approx -(-0.514) = 0.514 \text{ bits}$$

※ 자연로그(ln)를 쓸 경우에는:

$$H(P, Q) = -\ln 0.7 \approx 0.357 \text{ nats}$$

✓ 해석

- 모델이 정답인 강아지를 **70% 확률로 예측했으므로**,
- 예측은 꽤 괜찮았고,
- **크로스 엔트로피(손실)는 낮다 (0.514 bits)**
 - 만약 0.9였다면 더 낮고,
 - 0.3이라면 손실은 더 커짐

정리하면,

"크로스 엔트로피는 정답 분포 P 를 기준으로, 모델 예측 확률 Q 가 얼마나 신뢰할 만했는지를 로그 정보량으로 평가한 손실이다."


"정답에 가까울 확률일수록 손실이 작고, 멀어질수록 손실이 크다 "

쿨백 라이블러 발산 (kullback-Leibler Divergence)


“두 확률분포의 차이 측정하는 방법”

- 연산값이 0(차이없음) = 동일 분포
- 연산값이 클수록 서로 다른 분포

K-L Divergence



K-L Divergence



$$D_{KL}(P\|Q) = \int_{-\infty}^{\infty} p(x) \log \frac{p(x)}{q(x)} dx$$

“분류문제 손실함수로 크로스엔트로피 사용”

“두 분포의 차이를 줄이기 위해 KL-divergence 최소화 시킴”

“확률분포에서 로그비율(분수)만큼 떨어져 있다”

KL Divergence (클백 라이블러 발산)

- P와 Q의 차이 계산

- P(x): 우리가 가지고 있는 데이터의 분포; True distribution(참분포); 관찰데이터
- Q(x) : 모델이 추정한 데이터의 분포; 가설(Theory); 모델(Model)

KL 발산 정의


두 확률분포 $p(x)$ 와 $q(x)$ 가 있을 때,
이 둘이 **얼마나 다른지**를 측정하는 **비대칭 거리 개념**입니다.

수식:

$$D_{KL}(P \parallel Q) = \int p(x) \log \frac{p(x)}{q(x)} dx$$

- $p(x)$: 진짜 분포 (정답, 실제값)
- $q(x)$: 모델이 예측한 분포

$$\int p(x) \log \left(\frac{p(x)}{q(x)} \right) dx$$



1. 두 확률 분포의 비율
2. 정답값 $p(x)$ = 예측값 $q(x)$, 로그 1즉, 손실값 0
3. 정답값 1, 예측값 0.1 이면...로그 10
4. 정답값 1, 예측값 0.5 이면...로그 2
5. 예측값이 정확해 질 수록 로그 1에 가까워짐
 - 손실 0에 가까워짐
6. 예측값이 부정확 할 수록 로그 0에 가까워질 수록~
 - 손실값은 무한대로~

#크로스 엔트로피&엔트로피&KL발산

$$\text{Cross Entropy}(p, q) = \underbrace{H(p)}_{\text{정답 자체의 정보량}} + \underbrace{D_{KL}(p \parallel q)}_{\text{예측이 정답에서 얼마나 벗어났는지}}$$

기호	의미
$p(x)$	정답 분포 (ground truth)
$q(x)$	예측 분포 (모델 output, softmax 결과 등)
$H(p)$	정답 분포 자체의 정보량 (엔트로피)
$D_{KL}(p \parallel q)$	정답과 예측의 차이 (별점)
$\text{CE}(p, q)$	Cross Entropy (모델의 손실 함수로 사용)

KL 발산(Kullback–Leibler Divergence)은 확률분포 간의 *비대칭 거리*

#크로스 엔트로피&엔트로피&KL발산

크로스 엔트로피 = 엔트로피 + KL 발산

$$\text{Cross Entropy}(p, q) = \underbrace{H(p)}_{\text{정답 자체의 정보량}} + \underbrace{D_{KL}(p \parallel q)}_{\text{예측이 정답에서 얼마나 벗어났는지}}$$

- **엔트로피 $H(p)$:**
 - 정답 분포 자체의 정보량
 - 바꿀 수 없는 값 (상수)
- **KL 발산 $D_{KL}(p \parallel q)$:**
 - 예측이 정답에서 얼마나 멀리 벗어났는지를 측정
 - 작을수록 좋음
- **크로스 엔트로피:**
 - 실제 정답 기준에서 예측이 얼마나 정보적으로 손해를 보았는가

$$D_{KL}(P\|Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$$

- 정답인 $P(x)$: 기준, 우리가 신뢰하는 '진짜'
- 예측값 $Q(x)$: 모델이 낸 확률, 근사하려는 대상
- $\log \frac{P(x)}{Q(x)}$: 정답에 비해 예측이 얼마나 떨어져 있는가?

→ 이 값이 크면,

모델이 정답 $P(x)$ 에 해당하는 항목을 낮은 확률로 예측했던 뜻

→ 그래서 정보 손실(또는 거리)이 크다는 뜻

정리하면,

- KL 발산은 $P(x)$ 를 기준으로, 예측 분포 $Q(x)$ 가 얼마나 정답을 '어렵게' 예측했는지를 정보량(놀라움)으로 측정하고,
- 이를 $P(x)$ 의 가중치로 평균한 값이다.
- **정답 분포 $P(x)$ 기준으로**, $Q(x)$ 의 예측이 얼마나 틀렸는지(예측하기 어려운지)에 대한 가중 평균

<예시>

정답: $p = [1, 0]$

예측:

예측 q

Cross Entropy

KL Divergence

[1, 0]

0 (완벽)

0

[0.9, 0.1]

0.105

0.105

[0.01, 0.99]

6.64

6.64

→ 모델이 틀릴수록 Cross Entropy도 KL도 커짐

1. 엔트로피가 크면 무슨 뜻인가요?


- ① 엔트로피가 크다는 건, 그 확률분포가 불확실성(헛갈림)이 크다는 뜻
- ② 모든 선택지가 비슷한 확률일 때, 예측이 어렵고 → 정보량이 많음
- ③ 예를 들어 공정한 주사위처럼 1~6이 모두 똑같이 나올 확률이면 → 어떤 숫자가 나올지 전혀 모른다. 그래서 엔트로피가 크다.

2. 엔트로피는 꼭 로그를 써야 하나요?

① 네, 정보량은 로그로 표현함.

② Claude Shannon은 "정보량 함수

- 예측하기 힘들수록 정보량이 커야 함
- 확률이 독립일 경우 더할 수 있어야 함
- 연속성이 있어야 함



3. 엔트로피는 왜 '불확실성'을 측정하나요?

- ① 엔트로피는 본질적으로 "우리가 이 사건을 얼마나 **예측 못했는가**"를 수치로 표현한 개념 → **예측 불가능할수록 놀라움이 크고, 배울 정보도 많다.**
- ② 반대로 항상 같은 결과만 나온다면 → 새로 알게 되는 정보가 없으니 엔트로피는 0이 된다.

4. 크로스 엔트로피는 왜 손실 함수로 쓰이나요?

- ① 크로스 엔트로피는 $**$ "내 예측이 정답에서 얼마나 멀었는가" $**$ 를 측정하는 방식
- ② 예측값이 정답에 가까우면 $\rightarrow$ 손실이 작고,
- ③ 멀면 $\rightarrow$ 손실이 커짐
- ④ 그래서 분류 문제에서 모델이 학습할 방향을 알려주는 좋은 길잡이(loss function)

5. 엔트로피와 크로스 엔트로피는 어떻게 다르나요?

- ① 엔트로피 $H(P)$: 정답 확률분포 자체의 정보량 (얼마나 헛갈리는가?)
- ② 크로스 엔트로피 $H(P, Q)$: 정답 P 기준으로 예측 Q 가 얼마나 잘했는지 측정한 값

6. KL 발산은 도대체 왜 필요한가요?

- ① KL 발산은 두 확률분포(P, Q)가 얼마나 서로 다른지를 측정함.
- ② 정답 분포 P 와 모델의 예측 분포 Q 가 얼마나 다른지를 계산하고, $\rightarrow$ 이 차이를 줄이는 방향으로 모델을 학습시킴
- ③ 즉, 크로스 엔트로피 - 엔트로피 = KL 발산이기 때문에, 크로스 엔트로피를 줄이면 곧 KL 발산도 줄게 됩니다.

7. 예측 확률이 0에 가까우면 왜 위험한가요?

- ① 만약 정답은 1인데 모델이 그 확률을 0.0001로 예측했다면,
- ② $\log(1/0.0001) = \log(10000) = \text{약 } 9.21 \rightarrow$ 엄청난 손실이 발생함
- ③ 즉, 모델이 정답을 거의 불가능하다고 판단하면, 손실이 폭발적으로 커짐
- ④ 그래서 softmax 같은 함수도 예측값이 0에 완전히 도달하지 않도록 조절합니다.

8. 크로스 엔트로피가 0이 되려면 무슨 상황인가요?

- ① 모델의 예측 확률 Q 가 정답 분포 P 와 완벽히 같을 때,
- ② 즉, **정답 확률 1(퍼펙트)**
- ③ $\log(1) = 0 \rightarrow$ 손실값도 0이 됨
- ④ 즉, 완벽한 예측은 정보 손실이 없다는 뜻

9. KL 발산은 어느 모델에서 손실함수로 사용되는가?

Variational Autoencoder (VAE)

- 역할:
KL 발산은 잠재변수 분포 $q(z|x)$ 가 정규분포 $p(z)$ 와 얼마나 가까운지를 정규화합니다.
- 손실 함수 구성:

$$\mathcal{L}_{\text{VAE}} = \text{재구성 손실} + D_{\text{KL}}(q(z|x)||p(z))$$

- 재구성 손실: 입력을 얼마나 잘 복원했는가 (예: MSE, BCE)
- KL 발산: 잠재공간이 정규분포와 얼마나 유사한가 → 구조적 제약
- 왜 필요?
→ KL 항이 없으면 잠재공간이 무질서한 이상한 분포가 되어, 샘플링이 불가능함